Sockets TCP/IP en C

Di Paola Martín

martinp.dipaola <at> gmail.com

Facultad de Ingeniería
Universidad de Buenos Aires

De qué va esto?

- Redes TCP/IP (simplificado)
- Resolución de nombres
- Canal de comunicación TCP
  - Establecimiento de un canal
  - Envio y recepción de datos
  - Finalización de un canal
- Protocolos y formatos

Medios compartidos (simplificado)

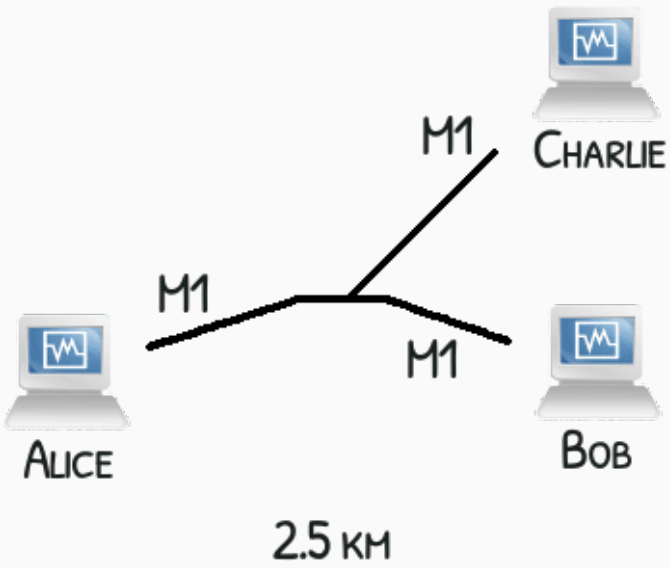

- Los mensajes son recibidos por todos (*shared*).

Medios compartidos (simplificado)

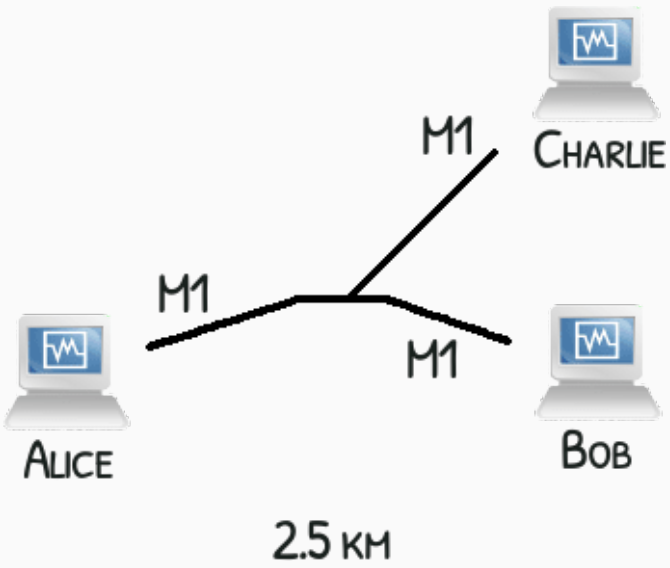

- Los mensajes son recibidos por todos (*shared*).
- No se requiere hardware adicional en la red.

Medios compartidos (simplificado)

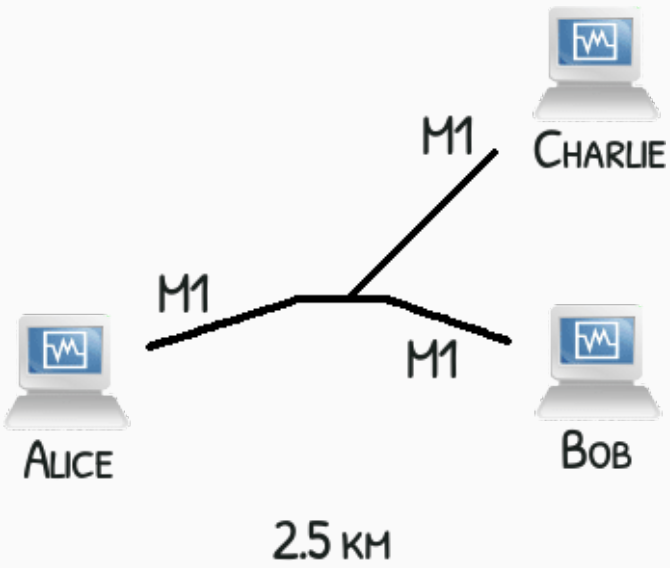

- Los mensajes son recibidos por todos (*shared*).
- No se requiere hardware adicional en la red.
- Solo un participante puede hablar a la vez:
  La performance se degrada a mayor cantidad de participantes.

Internet - Protocolo IP (simplificado)

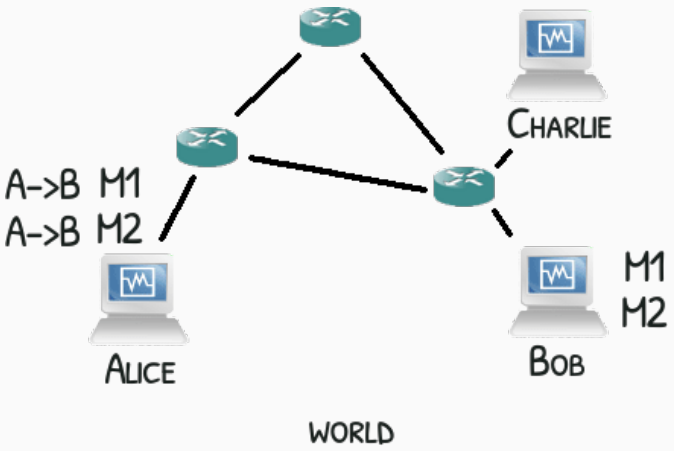

- Los mensajes son *ruteados* a sus destinos (*hosts*)

Internet - Protocolo IP (simplificado)

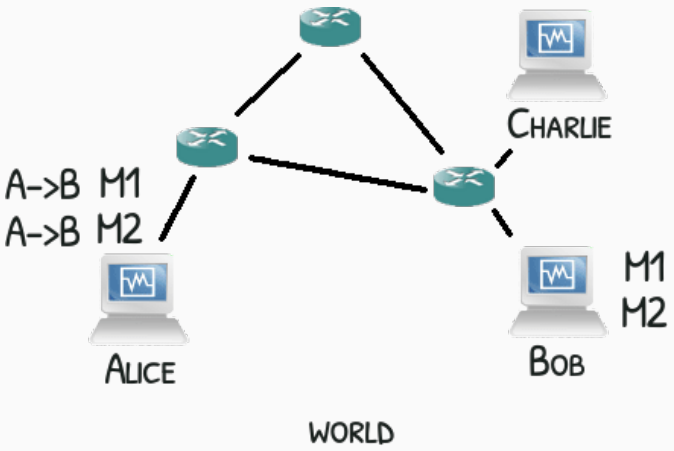

- Los mensajes son *ruteados* a sus destinos (*hosts*)
- Dos esquemas de direcciones: IPv4 (4 bytes) e IPv6 (16 bytes).

Internet - Protocolo IP (simplificado)

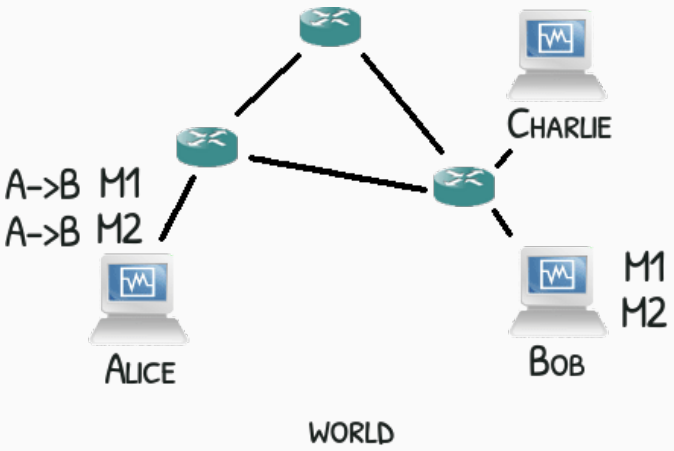

- Los mensajes son *ruteados* a sus destinos (*hosts*)
- Dos esquemas de direcciones: IPv4 (4 bytes) e IPv6 (16 bytes).
- Son redes *best effort*
  - Los paquetes se pueden perder.
  - Los paquetes puede llegar en desorden.
  - Los paquetes puede llegar duplicados.

Internet - Protocolo TCP (simplificado)

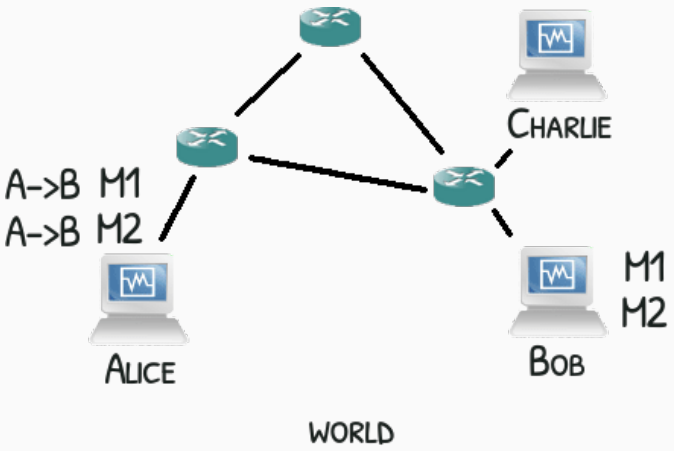

- Corre sobre IP, permite el direccionamiento a nivel de servicio (*port*)

Internet - Protocolo TCP (simplificado)

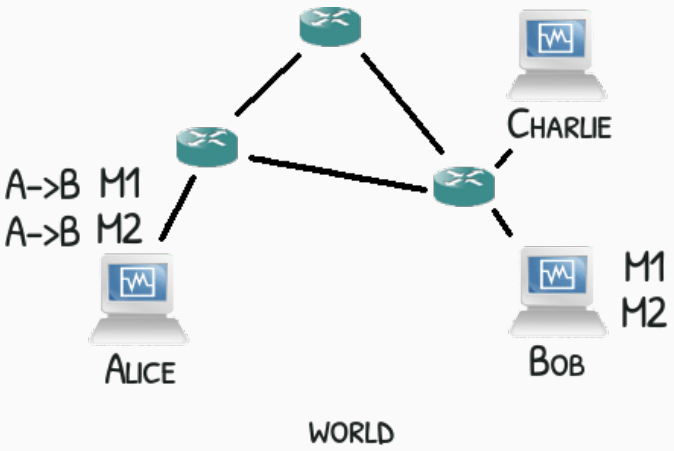

- Corre sobre IP, permite el direccionamiento a nivel de servicio (*port*)
- Orientado a bytes, no a mensajes (*stream*): los bytes no se pierden, desordenan ni duplican pero no garantiza *boundaries*

Internet - Protocolo TCP (simplificado)

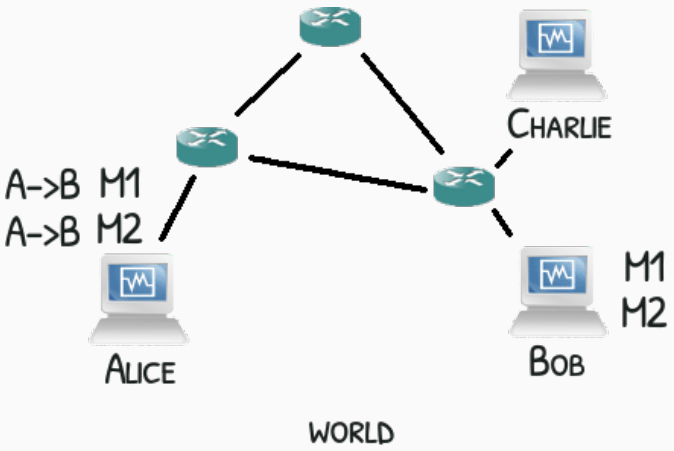

- Corre sobre IP, permite el direccionamiento a nivel de servicio (*port*)
- Orientado a bytes, no a mensajes (*stream*): los bytes no se pierden, desordenan ni duplican pero no garantiza *boundaries*
- Con conexión y full-duplex. Análogo a un archivo binario secuencial.

Internet - Protocolo DNS (simplificado)

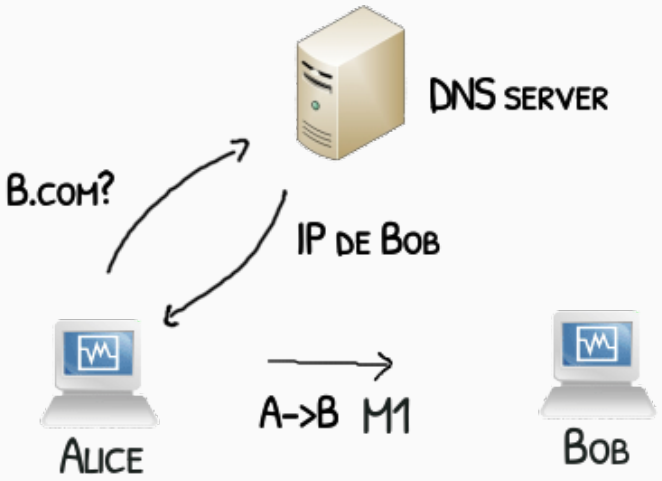

- No es necesario recordar la dirección IP del destino (4 o 16 bytes) sino su *nombre de dominio*.

Internet - Protocolo DNS (simplificado)

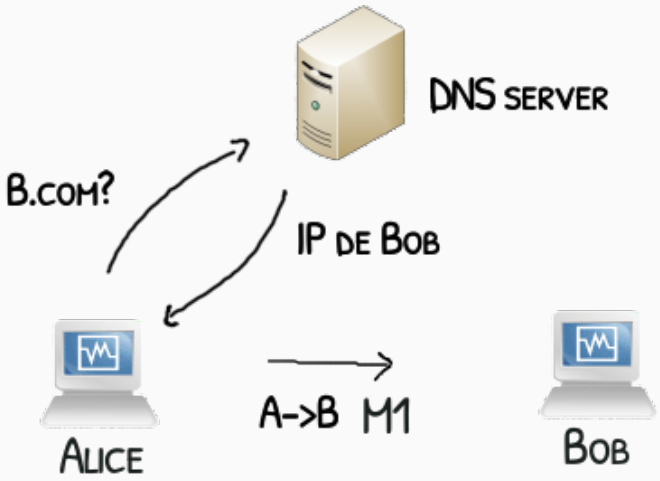

- No es necesario recordar la dirección IP del destino (4 o 16 bytes) sino su *nombre de dominio*.
- La registración de dominios se hace a nivel gubernamental. Para el caso `.com.ar` lo hace NIC, Cancillería Argentina.

Internet - Protocolo DNS (simplificado)

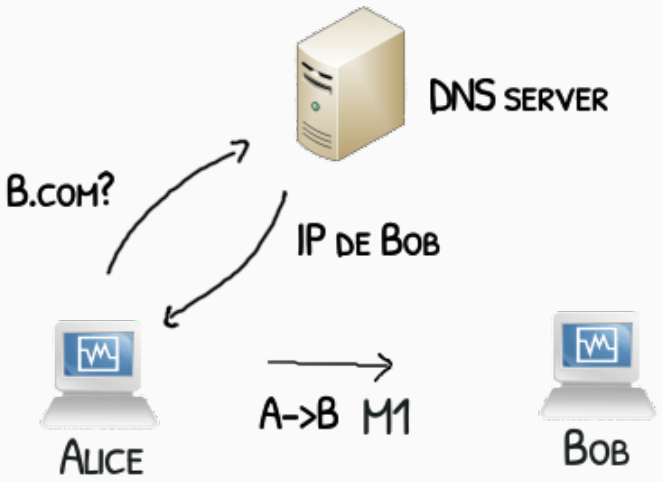

- No es necesario recordar la dirección IP del destino (4 o 16 bytes) sino su *nombre de dominio*.
- La registración de dominios se hace a nivel gubernamental. Para el caso `.com.ar` lo hace NIC, Cancillería Argentina.
- La resolución de un dominio a una o varias direcciones IP las hace el servidor de DNS.

Internet - Protocolo DNS (simplificado)

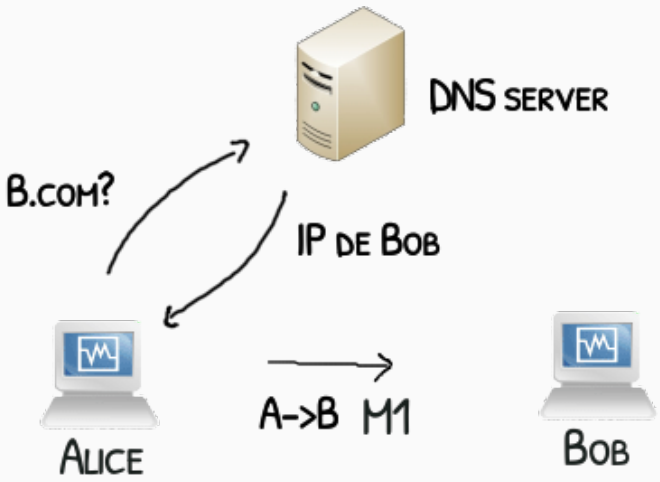

- No es necesario recordar la dirección IP del destino (4 o 16 bytes) sino su *nombre de dominio*.
- La registración de dominios se hace a nivel gubernamental. Para el caso `.com.ar` lo hace NIC, Cancillería Argentina.
- La resolución de un dominio a una o varias direcciones IP las hace el servidor de DNS.
- Un dominio puede tener múltiples IPs: por redundancia o por ser IPv4 e IPv6.

Resolución de nombres

Resolución de nombres: desde donde quiero escuchar

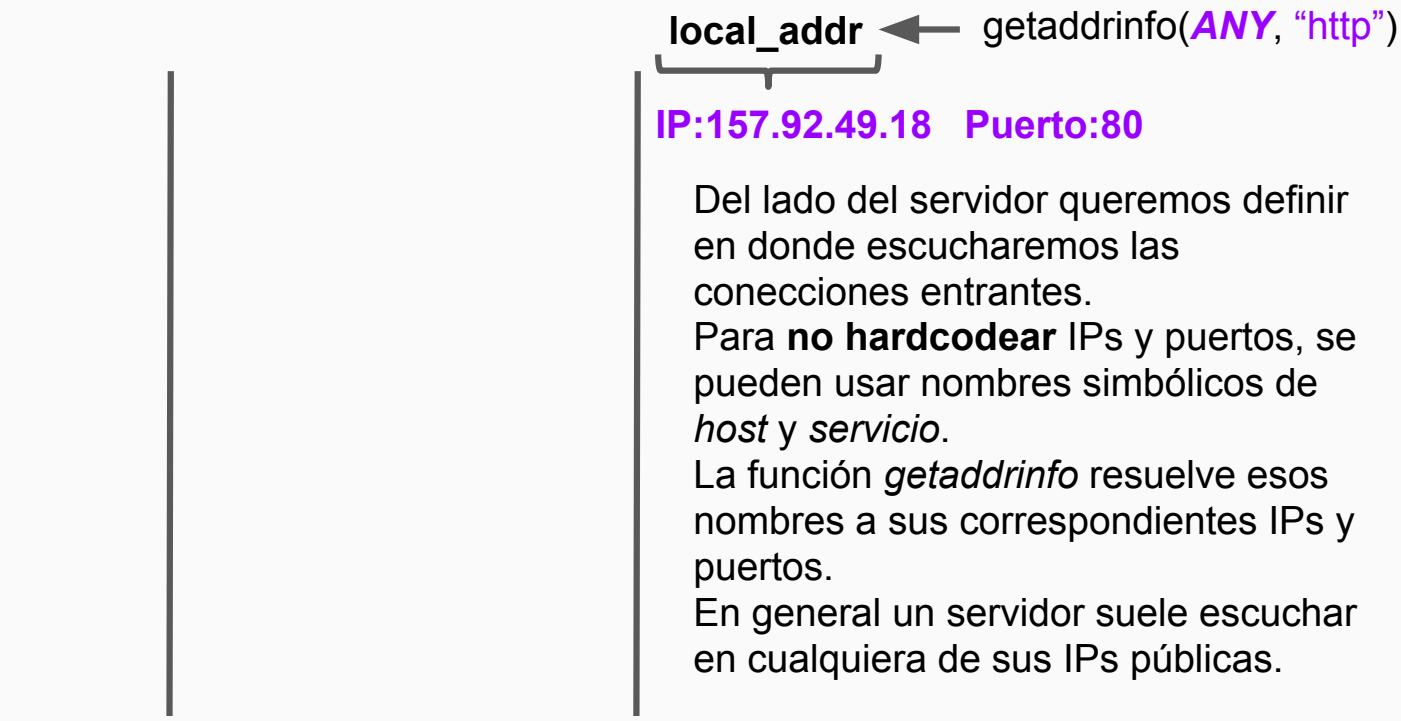

Resolución de nombres: a quien me quiero conectar

remote_addr ← getaddrinfo(“fi.uba”, “http”)

IP:157.92.49.18 Puerto:80

Del lado del cliente queremos definir a quien nos queremos conectar.

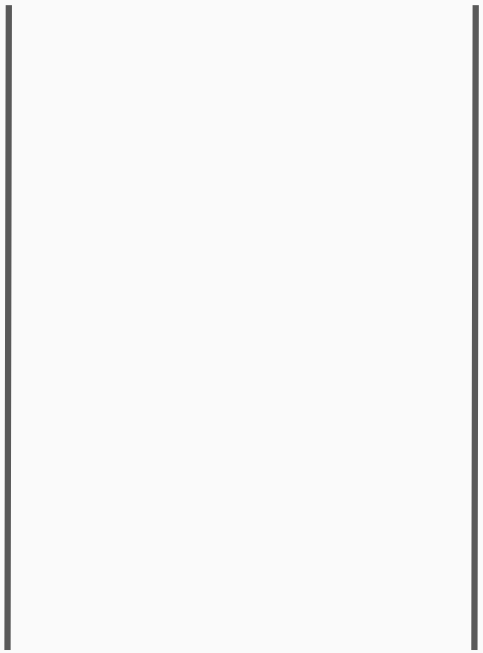

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Resolución de nombres

Cliente

```
1 memset(&hints, 0, sizeof(struct addrinfo));
2 hints.ai_family   = AF_INET;      /* IPv4  */
3 hints.ai_socktype = SOCK_STREAM;  /* TCP   */
4 hints.ai_flags    = 0;
5
6 status = getaddrinfo("fi.uba.ar", "http", &hints, &results);
```

Servidor

```
1 memset(&hints, 0, sizeof(struct addrinfo));
2 hints.ai_family   = AF_INET;      /* IPv4  */
3 hints.ai_socktype = SOCK_STREAM;  /* TCP   */
4 hints.ai_flags    = AI_PASSIVE;
5
6 status = getaddrinfo(0 /* ANY */, "http", &hints, &results);
```

```
1 freeaddrinfo(results);  // Cliente y Servidor
```

Canal de comunicación TCP

Establecimiento de un canal

Creación de un socket

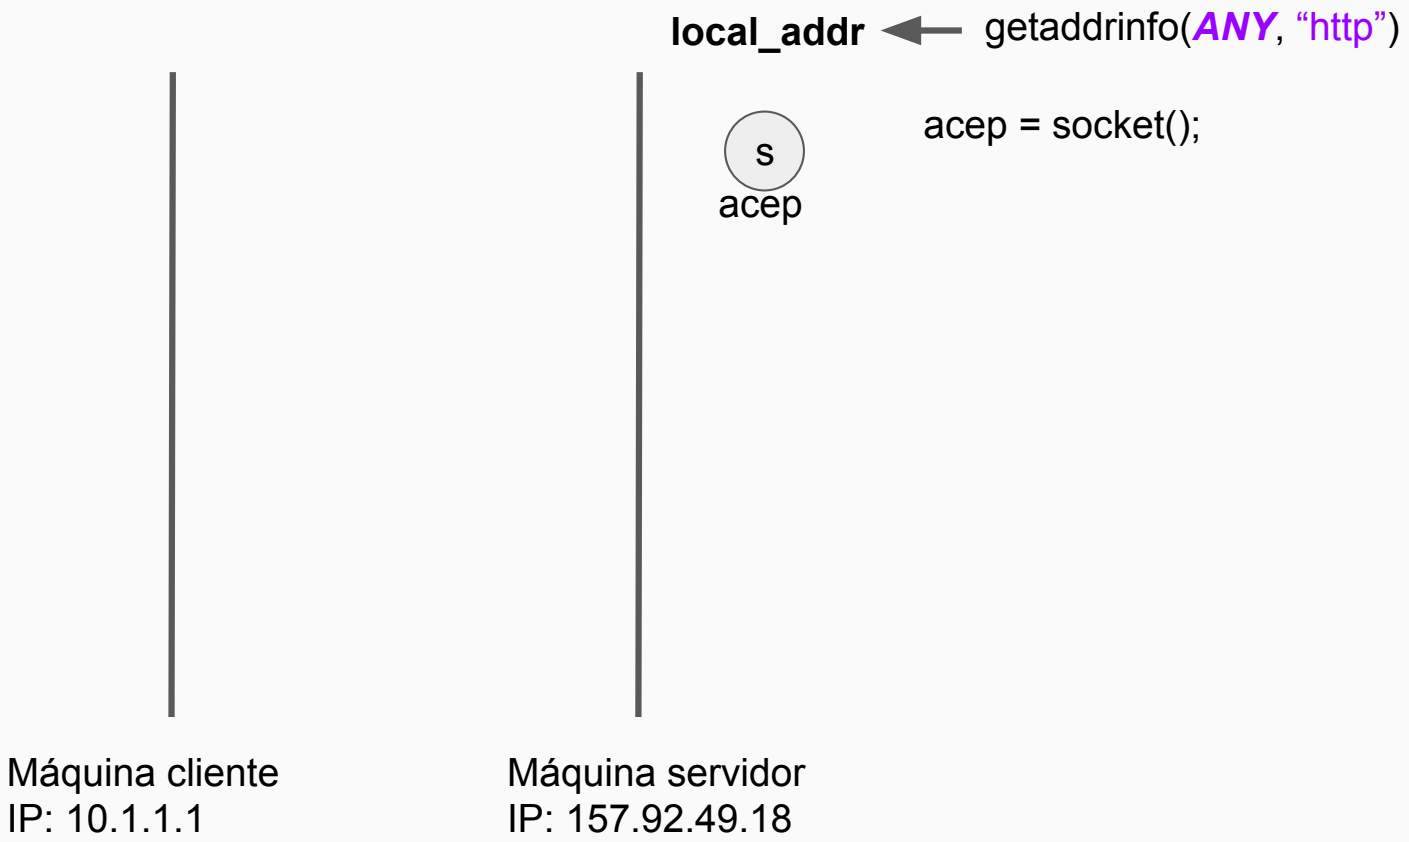

Enlazado de un socket a una dirección

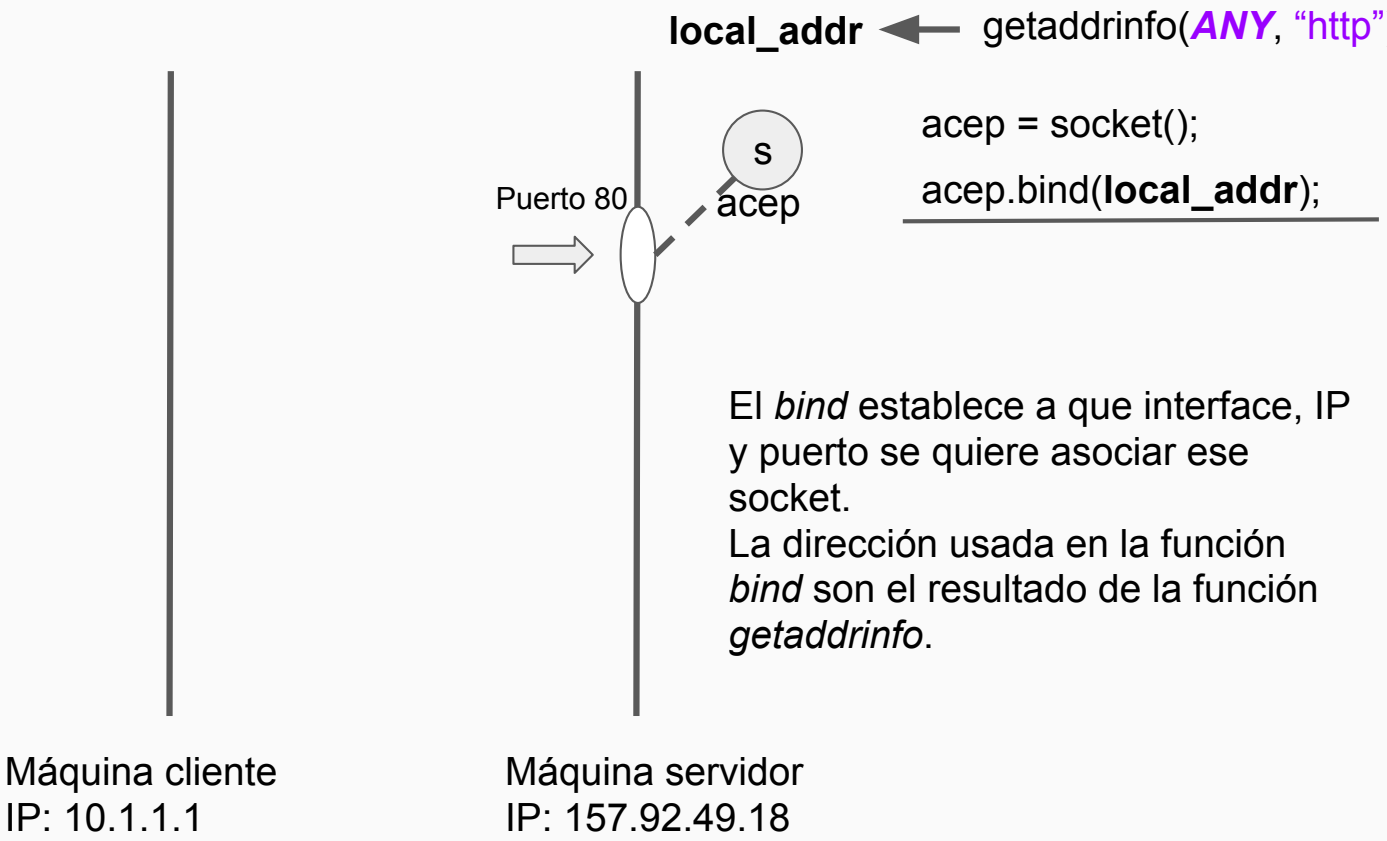

Socket aceptador o pasivo

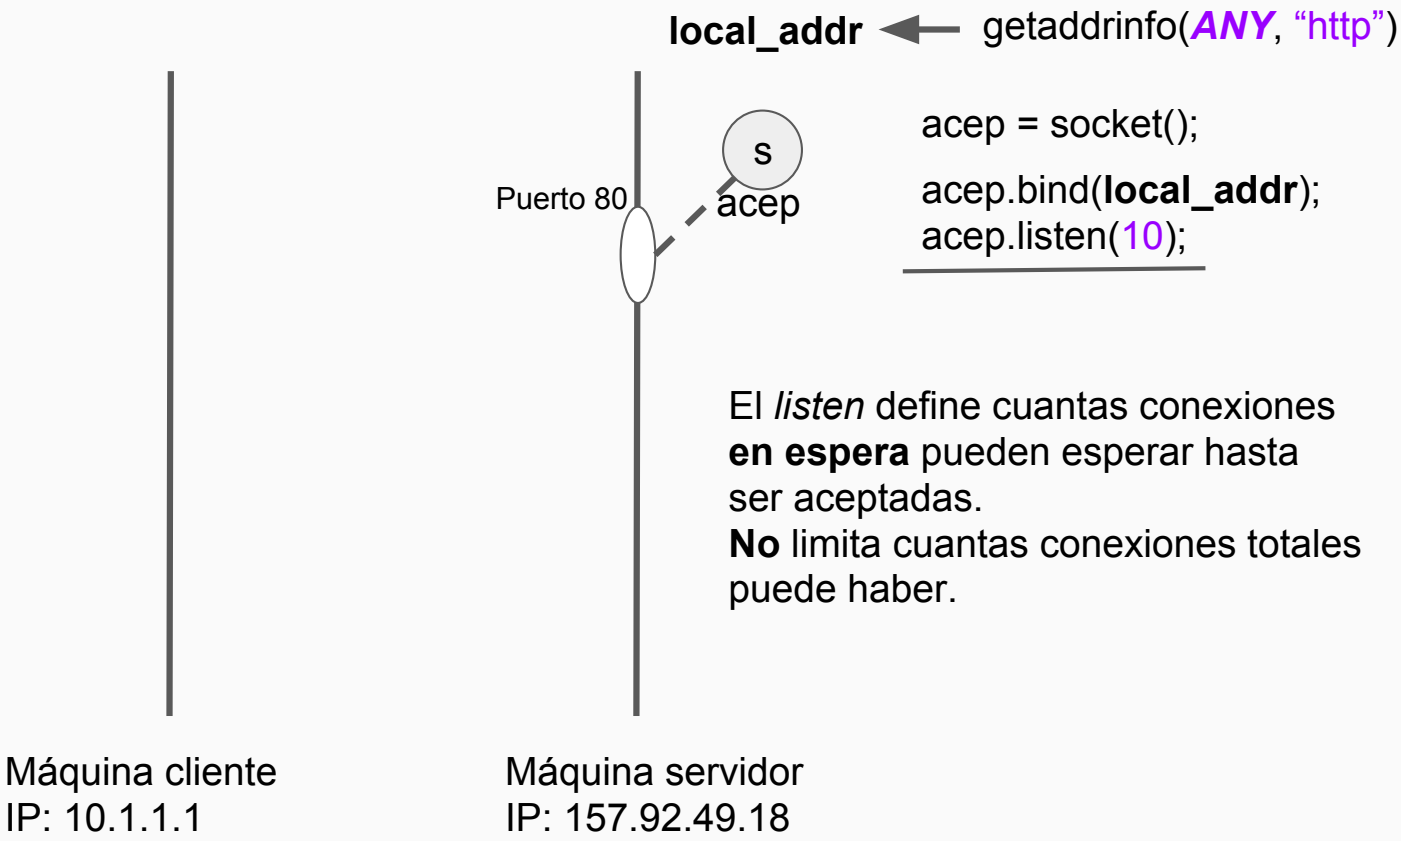

Socket aceptador o pasivo

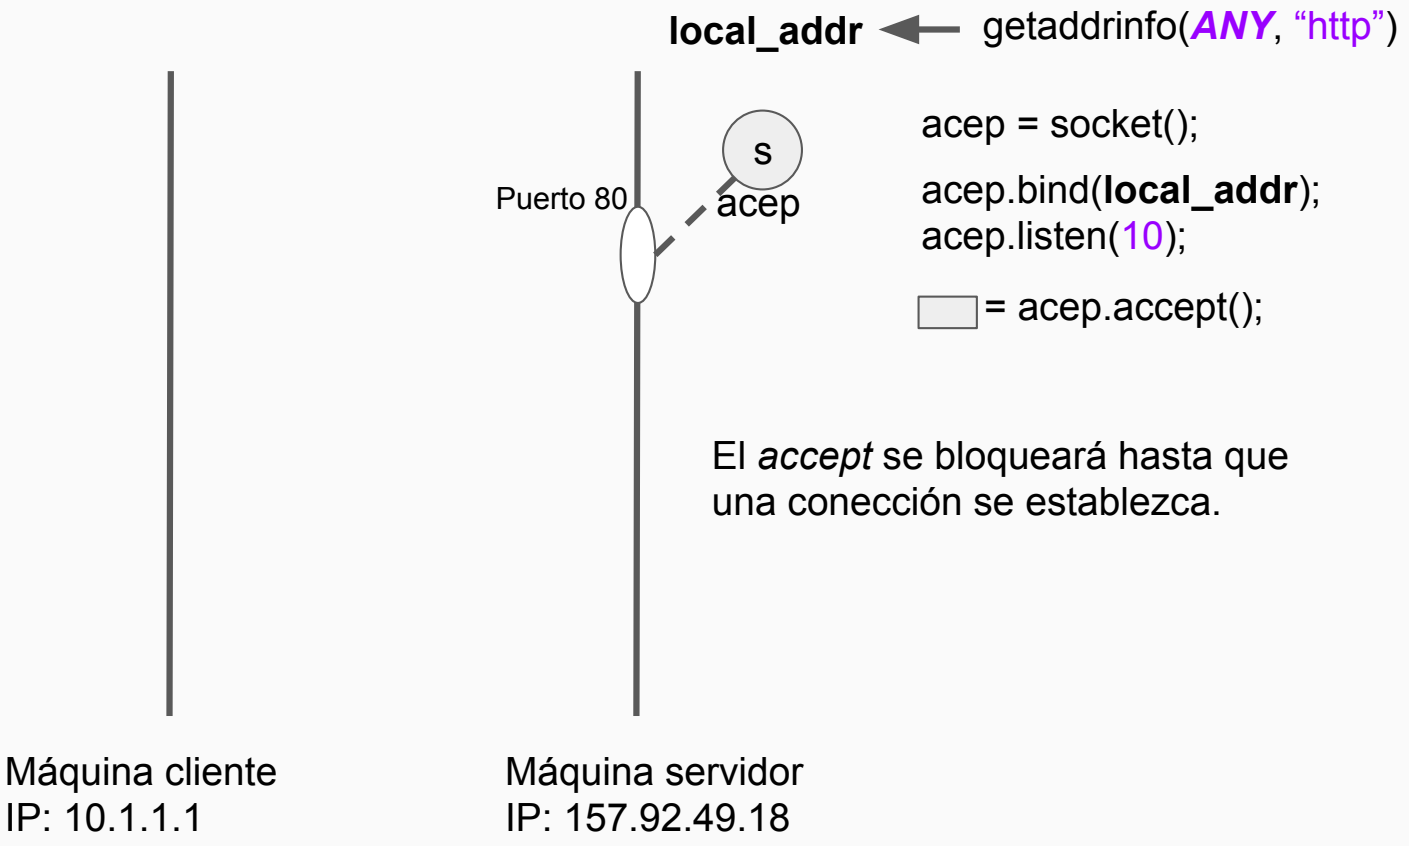

Conexión con el servidor: estableciendo conexión

remote_addr ← getaddrinfo(“fi.uba”, “http”)

cli = socket();

cli.connect(**remote_addr**);

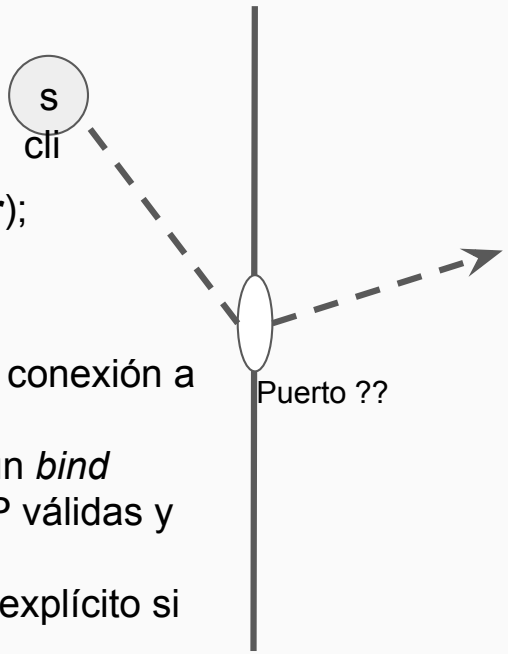

El *connect* establece una conexión a la máquina remota.
De forma implícita hace un *bind* eligiendo una interfaz e IP válidas y un puerto libre al azar.
Es posible hacer un *bind* explícito si se desea.

local_addr ← getaddrinfo(***ANY***, “http”)

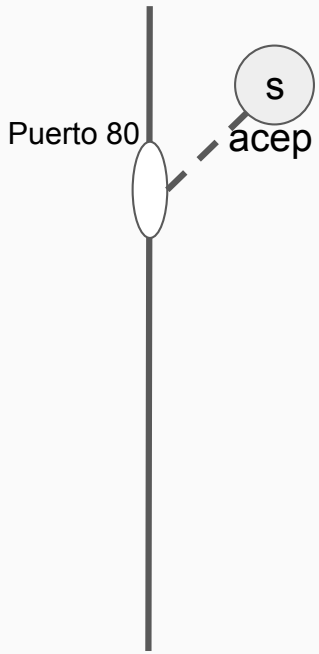

acep = socket();

acep.bind(**local_addr**);
acep.listen(10);

= acep.accept();

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Conexión con el servidor: aceptando la conexión

remote_addr ← getaddrinfo(“fi.uba”, “http”)

local_addr ← getaddrinfo(***ANY***, “http”)

cli = socket();

cli.connect(**remote_addr**);

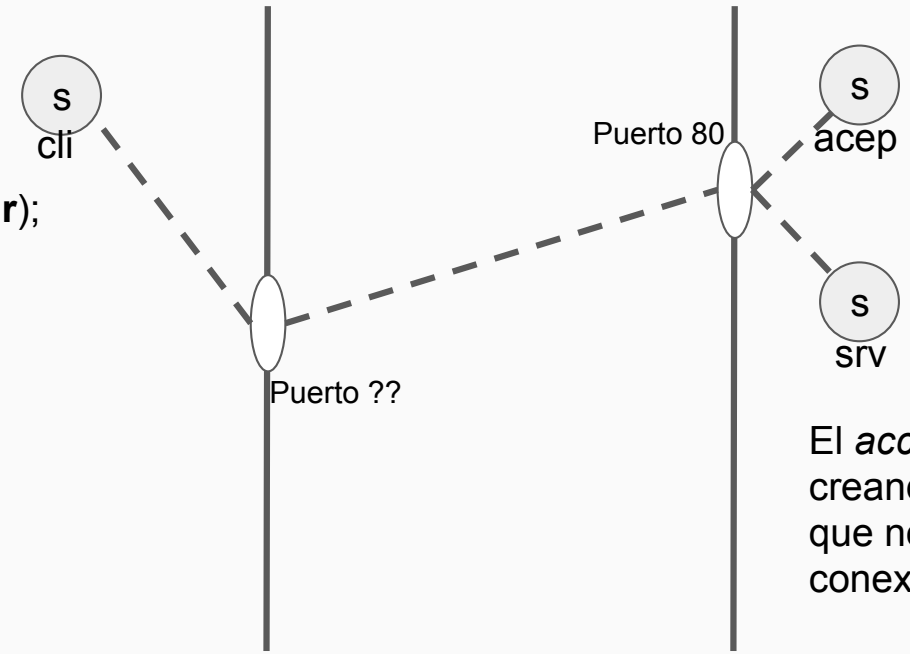

acep = socket();

acep.bind(**local_addr**);
acep.listen(10);

srv = acep.accept();

El *accept* se desbloquea creandonos **un segundo socket** que nos representa la nueva conexión establecida.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Canal de comunicación TCP

Envio y recepción de datos

Conexión establecida

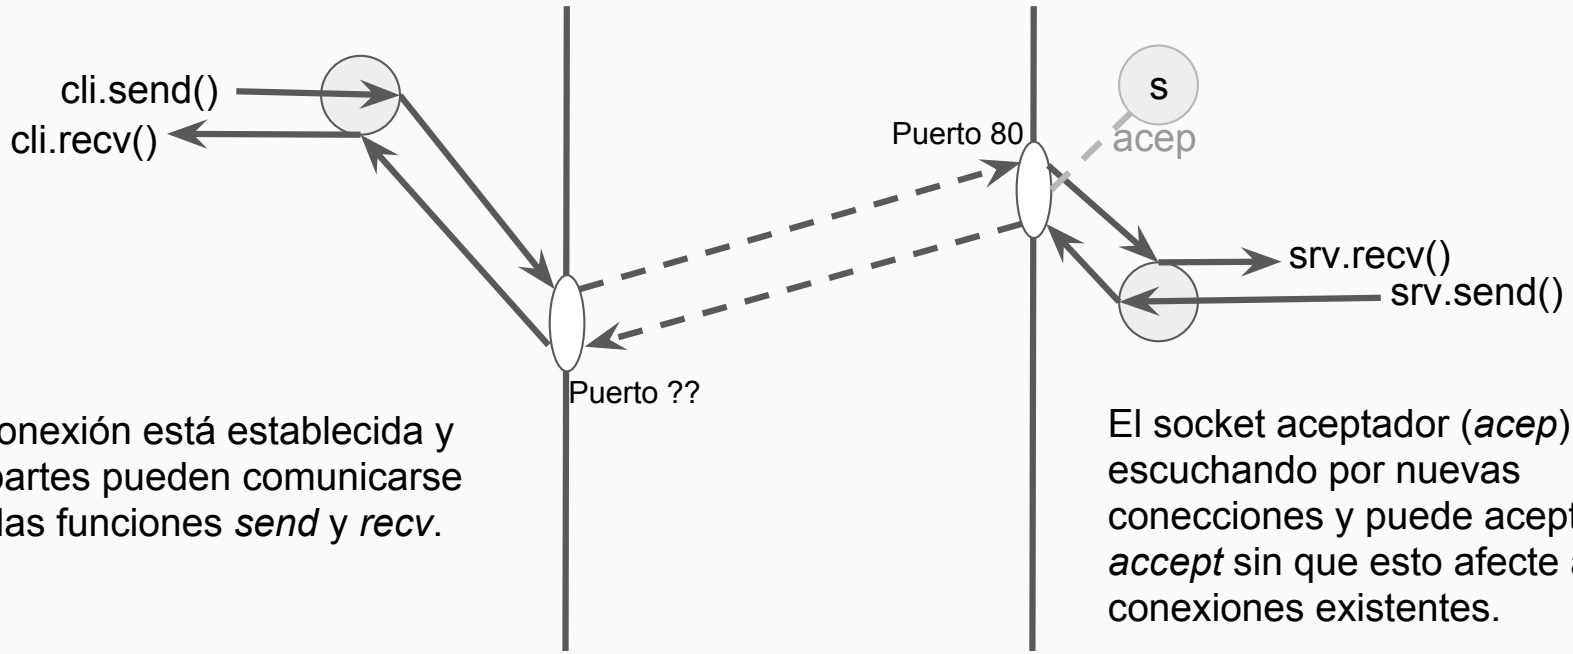

La conexión está establecida y las partes pueden comunicarse con las funciones *send* y *recv*.

El socket aceptador (*acep*) sigue escuchando por nuevas conecciones y puede aceptarlas con *accept* sin que esto afecte a las conexiones existentes.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Envio y recepción de datos

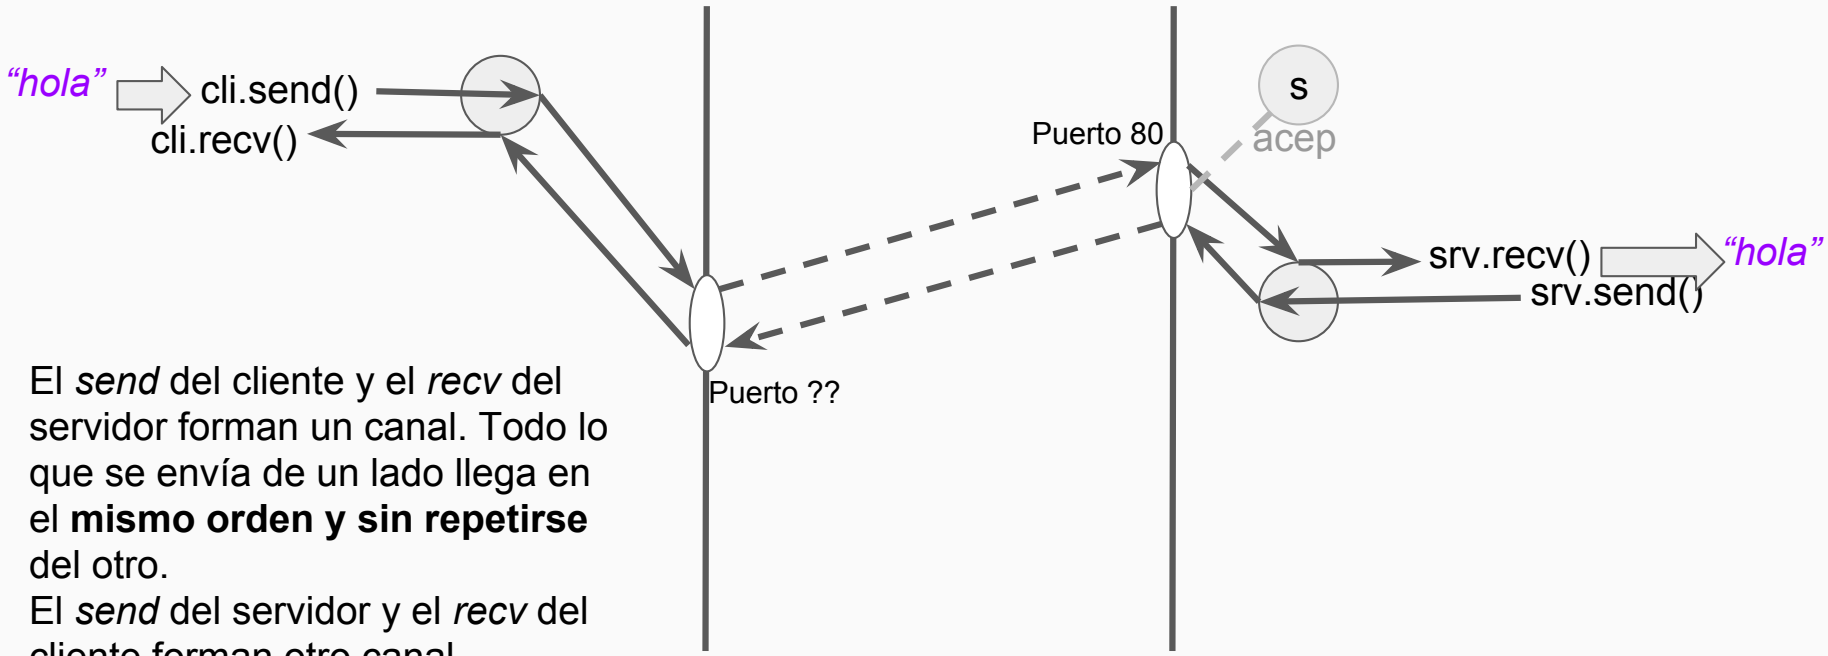

El *send* del cliente y el *recv* del servidor forman un canal. Todo lo que se envía de un lado llega en el **mismo orden y sin repetirse** del otro.
El *send* del servidor y el *recv* del cliente forman otro canal independiente. Esto se conoce como *Full Duplex*.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Envio y recepción de datos en la realidad

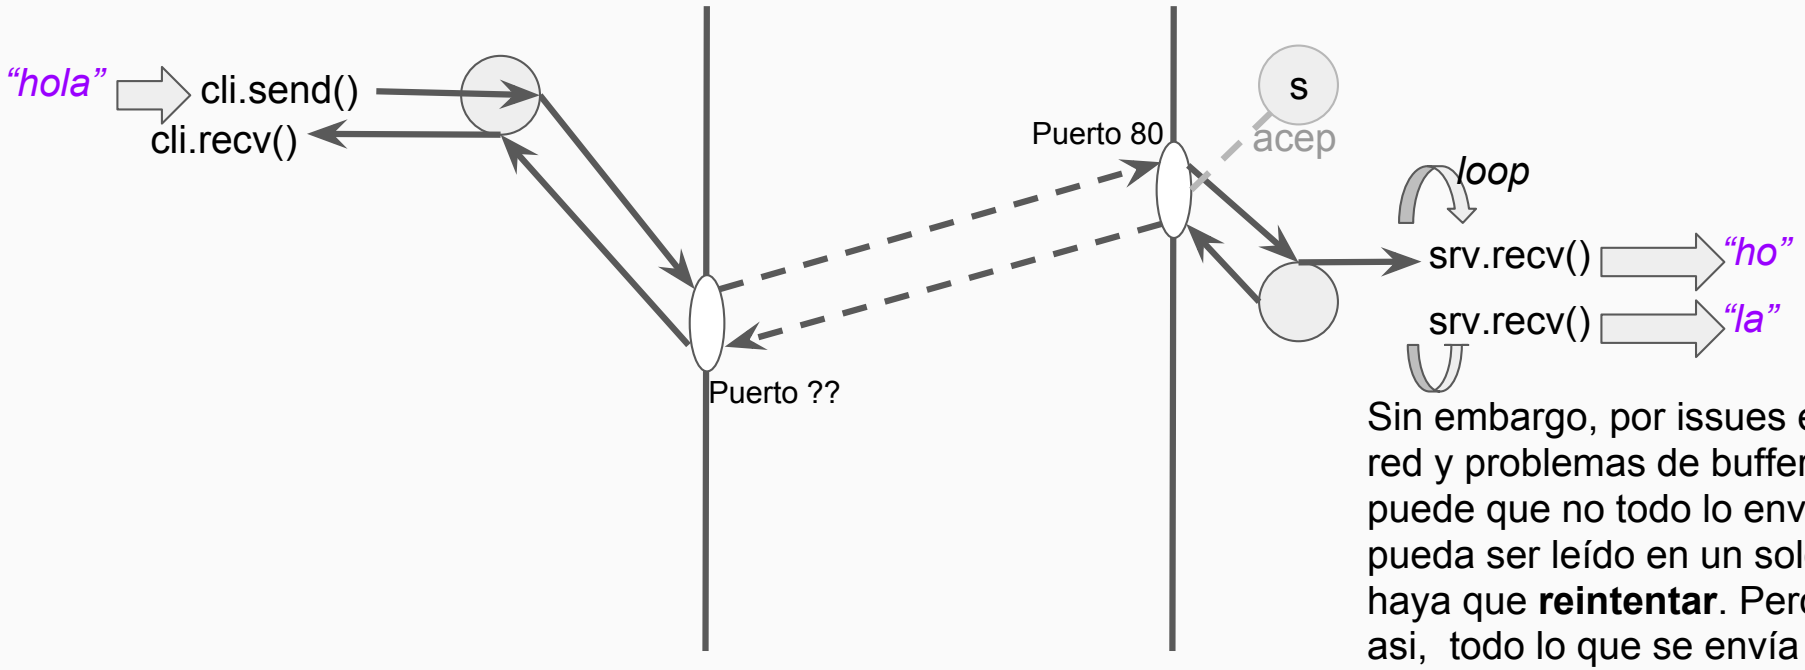

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Sin embargo, por issues en la red y problemas de bufferings puede que no todo lo enviado pueda ser leído en un solo recv y haya que **reintentar**. Pero aun asi, todo lo que se envía de un lado llega en el **mismo orden y sin repetirse** del otro.

Envio y recepción de datos en la realidad

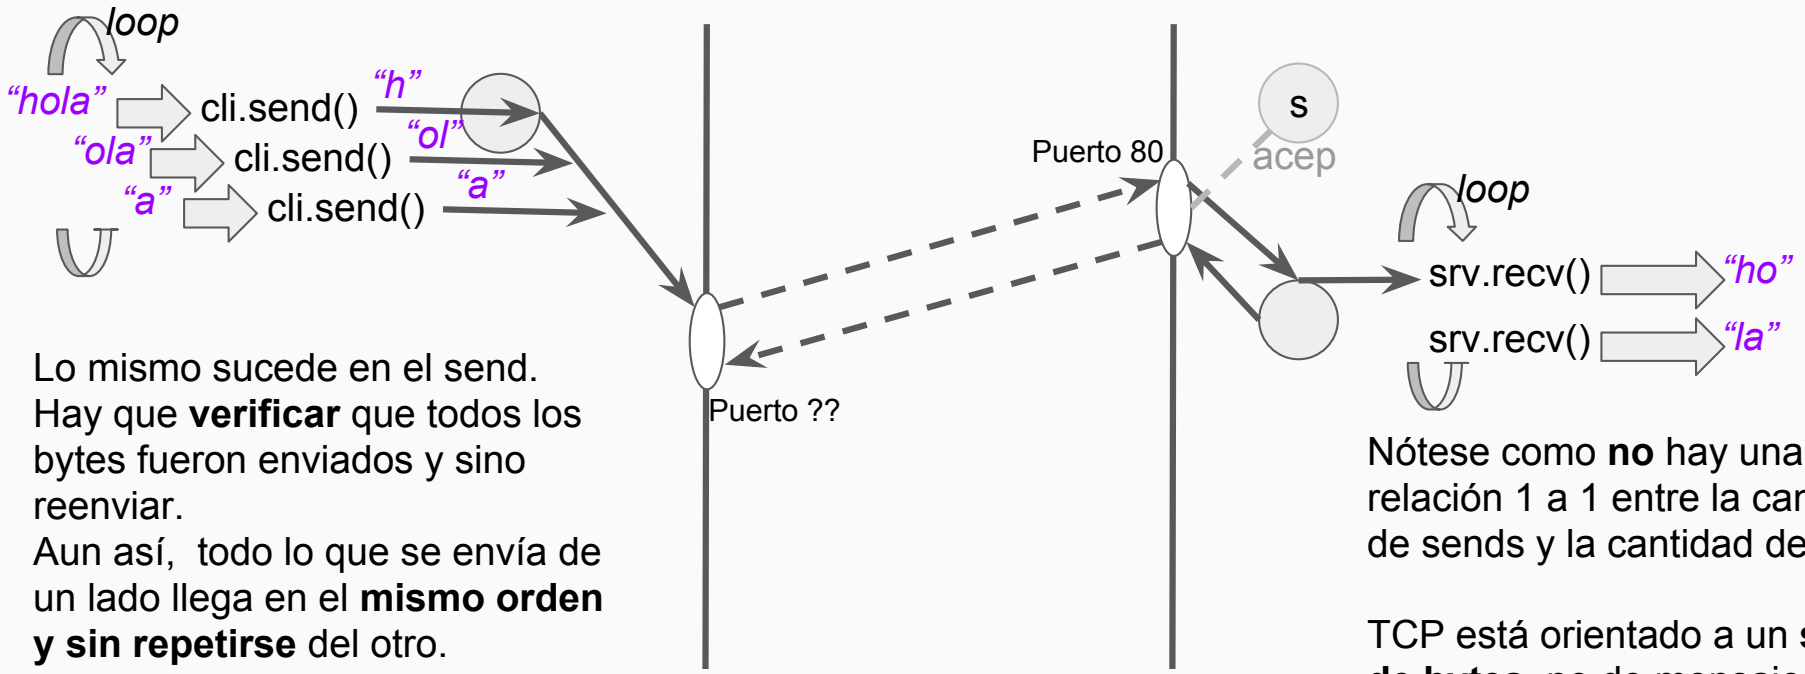

Lo mismo sucede en el send.
Hay que **verificar** que todos los bytes fueron enviados y sino reenviar.
Aun así, todo lo que se envía de un lado llega en el **mismo orden y sin repetirse** del otro.

Nótese como **no** hay una relación 1 a 1 entre la cantidad de sends y la cantidad de recvs.

TCP está orientado a un **stream de bytes**, no de mensajes.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Envio y recepción de datos

```
1  int s = send(skt,
2               buf,
3               bytes_to_sent,
4               flags           // MSG_NOSIGNAL
5             );
6
7  int s = recv(skt,
8               buf,
9               bytes_to_recv,
10              flags           // 0
11            );
12
13   (s == -1)  // Error inesperado, ver errno
14    (s == 0)  // El socket fue cerrado
15     (s > 0)  // Ok: s bytes fueron enviados/recibidos
```

recvall: recepción de N bytes exactos

```
1  char buf[MSG_LEN];  // buffer donde guardar los datos
2  int bytes_recv = 0;
3
4  while (MSG_LEN > bytes_recv && skt_still_open) {
5    s = recv(skt, &buf[bytes_recv], MSG_LEN - bytes_recv,
6                                                      0);
7    if (s == -1) { // Error inesperado, ver errno
8       /* ... */
9    }
10   else if (s == 0) { // Nos cerraron el socket
11      /* ... */
12   }
13   else {
14     bytes_recv += s;
15   }
16 }
```

sendall: envío de N bytes exactos

```
1  char buf[MSG_LEN];     // buffer con los datos a enviar
2  int bytes_sent = 0;
3
4  while (MSG_LEN > bytes_sent && skt_still_open) {
5    s = send(skt, &buf[bytes_sent], MSG_LEN - bytes_sent,
6                                                MSG_NOSIGNAL);
7    if (s == -1) { // Error inesperado, ver errno
8       /* ... */
9    }
10   else if (s == 0) { // Nos cerraron el socket
11      /* ... */
12   }
13   else {
14     bytes_sent += s;
15   }
16 }
```

Canal de comunicación TCP

Finalización de un canal

Cierre de conexión parcial

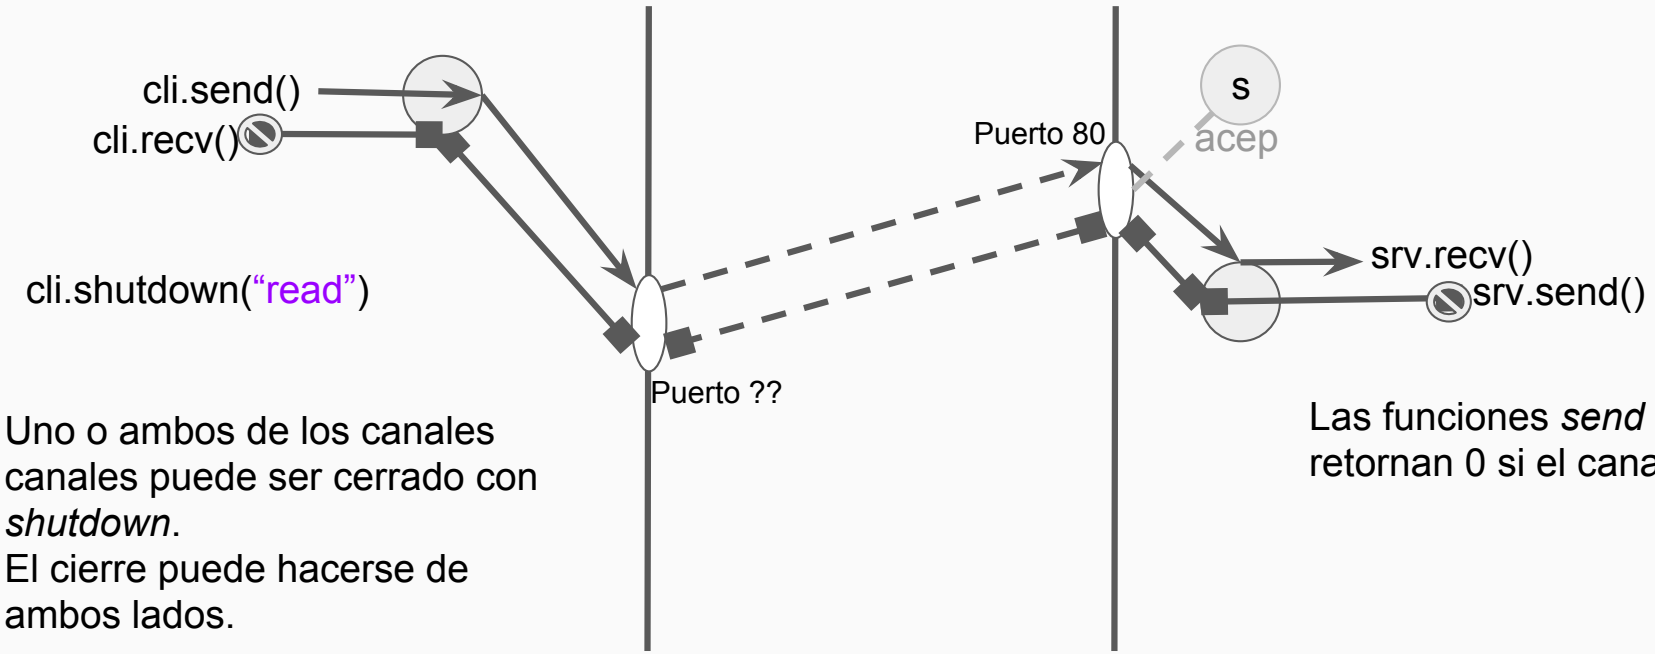

Uno o ambos de los canales canales puede ser cerrado con *shutdown*.
El cierre puede hacerse de ambos lados.

Las funciones *send* y *recv* retornan 0 si el canal fue cerrado.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Cierre de conexión total

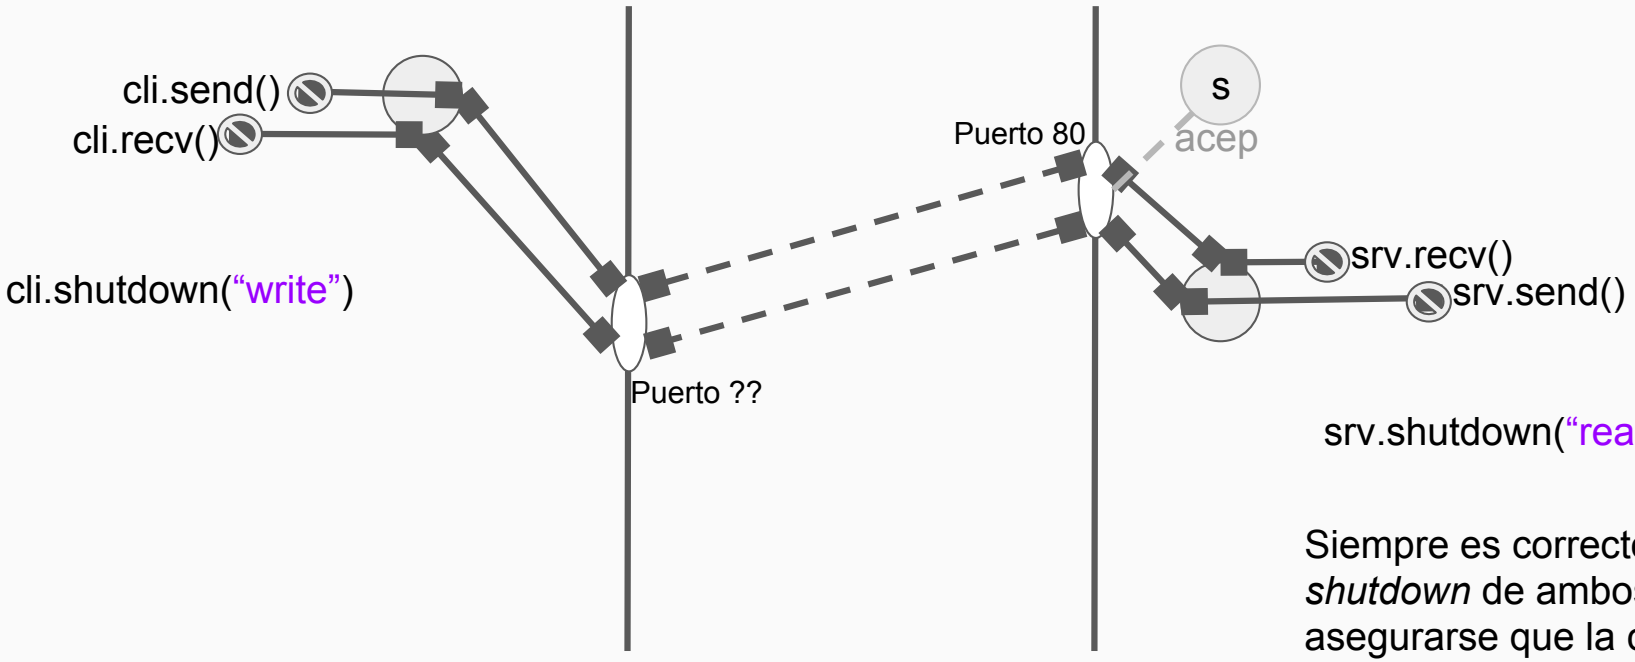

Siempre es correcto hacer un *shutdown* de ambos lados para asegurarse que la conexión está cerrada.

Liberación de los recursos con close

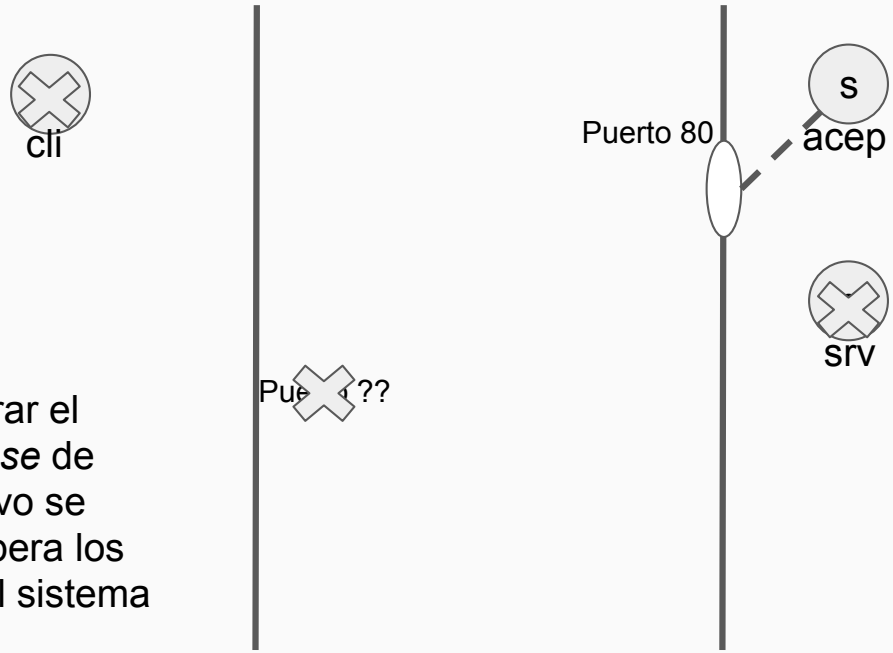

Luego, es necesario cerrar el socket con la función *close* de igual forma que un archivo se cierra con *fclose*. Esto libera los recursos asociados en el sistema operativo

Del lado del server hay que hacer lo mismo.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

Cierre y liberación del socket aceptador

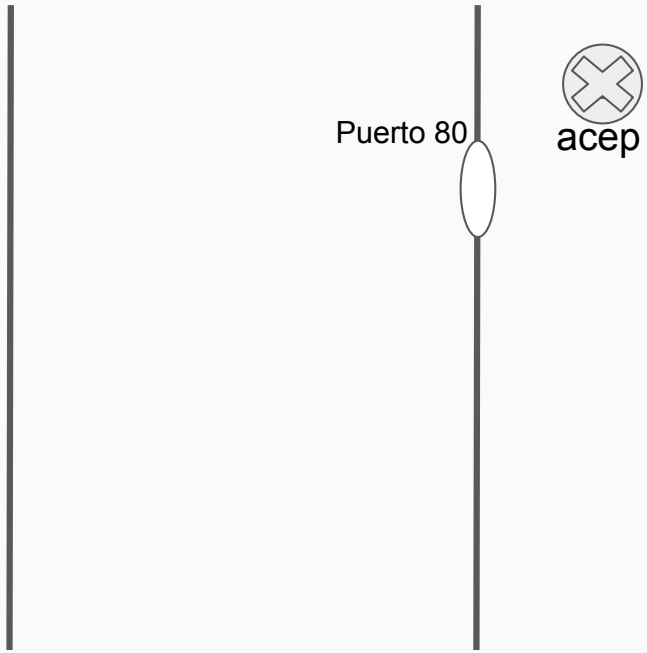

acep.shutdown(“read-write”)
acep.close()

Finalmente, para cerrar el socket aceptador hay que hacer un *shutdown* y un *close*.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

TIME WAIT

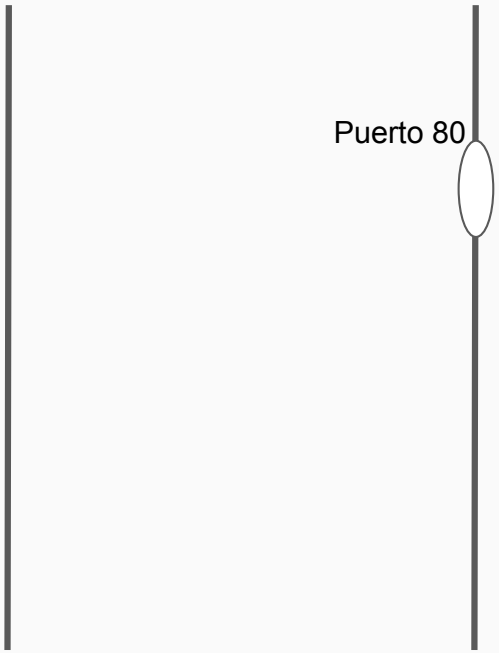

A pesar de haber hecho un *shutdown* y un *close*, el puerto queda en un estado especial llamado TIME_WAIT (incluso si el proceso terminó)

Esto es forzado por el sistema operativo para evitar “ciertos problemas”

Después de unos segundos el puerto queda libre para volver a ser usado.

Máquina cliente
IP: 10.1.1.1

Máquina servidor
IP: 157.92.49.18

TIME WAIT -> Reuse Address

Si el puerto 80 esta en el estado TIME WAIT, esto termina en error (Address Already in Use):

```
1 int acep   = socket(...);
2 int status = bind(acep, ...); //bind al puerto 80
```

TIME WAIT -> Reuse Address

Si el puerto 80 esta en el estado TIME WAIT, esto termina en error (Address Already in Use):

```
1 int acep   = socket(...);
2 int status = bind(acep, ...); //bind al puerto 80
```

La solución es configurar al socket aceptador para que pueda reusar la dirección:

```
1 int acep   = socket(...);
2
3 int val = 1;
4 setsockopt(acep, SOL_SOCKET, SO_REUSEADDR, &val, sizeof(val));
5
6 int status = bind(acep, ...); //bind al puerto 80
```

Protocolos y formatos

Binario o Texto

- Protocolos en Texto: son la contracara de los protocolos binarios, son lentos, ineficientes y más difíciles de parsear pero más fáciles de debuggear. Son independientes del endianess, padding y otros pero dependen del encoding del texto y que caracteres se usan como delimitadores.
- Protocolos en Binario: son simples y eficientes en terminos de memoria y velocidad de procesamiento. Son más difíciles de debuggear. Es necesario tomar en consideración el endianess, el padding, los tamaños y los signos.

HTTP

```
1 GET /index.html HTTP/1.1\r\n
2 Host: www.fi.uba.ar\r\n
3 \r\n
```

- En HTTP el fin del mensaje esta dado por una línea vacia; cada línea esta delimitada por un `\r\n`
- Cuantos bytes reservarían para contener dicho mensaje o alguna línea?
- Que pasa si el delimitador `\r\n` aparece en el medio de una línea, como lo diferenciarían?

TLV

```
1  struct Msj {
2      unsigned short type;
3      unsigned short length;
4      char* value;
5  };
6
7  read(fd, &msj.type, sizeof(unsigned short) * 2);
8  msj.value = (char*) malloc(msj.length);
9  read(fd, msj.value, msj.length);
```

- Los primeros 4 bytes indican la longitud y tipo del valor; el resto de los bytes son el valor en sí.
- Por qué es importante usar `unsigned short` y no solamente `short`? Qué pasa si `sizeof(unsigned short)` no es 2?
- Que pasa si el endianess no coincide? y si hay padding entre los dos primeros campos?

Appendix

Referencias

Referencias I

- man getaddrinfo
- man netcat
- man netstat
- RFCs 971, 2460, ...
- RFCs 793, ...
- TCP/IP Illustrated, Richard Stevens
- Data and Computer Comunications, Ed Stallings